ТЕХНИЧЕСКОЕ ЗАДАНИЕ

на выполнение выпускной квалификационной работы на тему:
«Разработка серверной части и инфраструктуры
самообучающейся FAQ-системы Sofa AI»

1 Наименование

Полное наименование: «Разработка серверной части и инфраструктуры самообучающейся FAQ-системы Sofa AI для малого и среднего бизнеса».

Краткое наименование: «Sofa AI — backend и MLOps-инфраструктура».

Условное обозначение: Sofa AI.

2 Назначение

Sofa AI — самообучающаяся FAQ-система на базе искусственного интеллекта, предназначенная для малого и среднего бизнеса. Компания загружает в систему свою базу знаний — часто задаваемые вопросы и ответы. ИИ-агент обрабатывает запросы клиентов на основе этих данных. Если система сталкивается с неизвестным вопросом, она переадресует его живым менеджерам; получив от них ответ, ИИ дообучается на этой информации и пополняет базу знаний. Таким образом, система постоянно повышает качество ответов, сокращая нагрузку на персонал.

Настоящая ВКР посвящена серверной части и инфраструктуре системы. Цель — создание NLP-модели для обработки естественного языка и построение автоматизированной инфраструктуры её развёртывания с использованием технологий контейнеризации и оркестрации. Ключевой особенностью является реализация конвейера непрерывной интеграции и доставки (CI/CD), обеспечивающего автоматическое тестирование, версионирование и развёртывание модели в облачной среде, а также механизм дообучения модели на основе обратной связи от пользователей.

Фронтенд-часть (веб-интерфейс и панель управления) разрабатывается тимейтом в рамках смежной ВКР.

3 Основание для разработки

Основанием для выполнения работы являются:

1) Учебный план Университета ИТМО, предусматривающий выполнение выпускной квалификационной работы бакалавра.
2) Задание на ВКР, утверждённое руководителем и согласованное в ИСУ ИТМО.
3) Положение о государственной итоговой аттестации обучающихся в Университете ИТМО (ЛНАОБУЧ-СМК-03-05-2022, версия 4.0).
4) ГОСТ 7.32-2017 «Отчёт о научно-исследовательской работе. Структура и правила оформления».

4 Функции

В рамках данной ВКР реализуются следующие функции серверной части и инфраструктуры Sofa AI:

4.1 Обработка запросов (NLP-модель)

- приём текстового вопроса клиента через API;
- семантический поиск наиболее релевантного ответа в базе знаний компании;
- определение степени уверенности модели в ответе (confidence score);
- возврат ответа клиенту при высокой уверенности либо эскалация менеджеру при низкой.

4.2 Механизм дообучения (Self-Learning Loop)

- фиксация вопросов, на которые модель не смогла ответить;
- передача таких вопросов менеджерам через очередь задач;
- приём ответов от менеджеров и сохранение пары «вопрос–ответ» в базу знаний;
- автоматическое дообучение (fine-tuning) модели на новых данных;
- версионирование дообученных моделей.

4.3 Управление базой знаний

- загрузка и обновление FAQ-базы компании через API;
- валидация и предобработка входных данных;
- индексация базы знаний для быстрого семантического поиска;
- поддержка нескольких независимых баз знаний (мультитенантность).

4.4 CI/CD и развёртывание

- автоматическая сборка Docker-образов при обновлении кода;
- автоматическое тестирование (unit, integration, model validation);
- развёртывание сервисов в Kubernetes-кластере;
- стратегии обновления: rolling update, canary deployment;
- автоматический откат при обнаружении проблем.

4.5 Мониторинг и наблюдаемость

– сбор метрик производительности: время отклика, throughput, error rate;
– мониторинг качества ответов модели (доля эскалаций, средний confidence);
– алертинг при деградации качества или сбоях;
– визуализация метрик в дашборде (Grafana).

5 Структура

5.1 Архитектура серверной части

1) **API Gateway (FastAPI)** — точка входа для всех запросов: приём вопросов от клиентов, управление базой знаний, взаимодействие с фронтендом.
2) **NLP Service** — сервис обработки естественного языка: векторизация вопросов, семантический поиск по базе знаний, генерация ответов. Использует модели на базе Sentence-Transformers / LLM.
3) **Knowledge Base Service** — управление FAQ-базами: CRUD-операции, индексация, мультитенантность.
4) **Escalation Service** — обработка эскалаций: очередь неотвеченных вопросов, взаимодействие с менеджерами, приём ответов.
5) **Retraining Service** — сервис дообучения: сбор новых пар «вопрос–ответ», запуск fine-tuning, валидация новой модели, публикация в Model Registry.
6) **Storage Layer** — PostgreSQL для метаданных, векторная БД (Qdrant/Milvus) для эмбеддингов, S3-совместимое хранилище (MinIO) для артефактов моделей.

5.2 Технологический стек

Категория	**Технологии**
Язык	Python 3.11+
Backend	FastAPI, Celery
ML / NLP	Sentence-Transformers, PyTorch, MLflow
Векторный поиск	Qdrant / Milvus
Контейнеризация	Docker
Оркестрация	Kubernetes
CI/CD	GitHub Actions, Argo CD
Мониторинг	Prometheus, Grafana
Хранение данных	PostgreSQL, MinIO (S3)
IaC	Terraform, Helm

5.3 Структура ВКР

Текст выпускной квалификационной работы включает:

1) Введение — актуальность, цели и задачи.
2) Обзор предметной области — анализ существующих FAQ-систем, MLOps-подходов.
3) Проектирование — архитектура системы, обоснование выбора технологий.
4) Реализация — разработка NLP-модели, backend-сервисов, инфраструктуры.
5) Тестирование и апробация — функциональное и нагрузочное тестирование.
6) Заключение — выводы, перспективы развития.

6 Пользовательский интерфейс

В рамках данной ВКР разрабатываются серверные интерфейсы взаимодействия. Графический веб-интерфейс является предметом смежной ВКР.

6.1 REST API

Основной интерфейс — REST API на базе FastAPI с автодокументацией (OpenAPI 3.0). Ключевые эндпоинты:

- `POST /api/v1/ask` — отправка вопроса и получение ответа;
- `POST /api/v1/knowledge` — загрузка/обновление базы знаний;
- `GET /api/v1/escalations` — список вопросов, ожидающих ответа менеджера;
- `POST /api/v1/escalations/{id}/resolve` — ответ менеджера на эскалированный вопрос;
- `GET /api/v1/models` — список версий модели и их метрики;
- `POST /api/v1/retrain` — запуск дообучения модели.

6.2 Webhook-интеграции

Для подключения к мессенджерам и чат-виджетам предусмотрен механизм вебхуков:

- приём входящих сообщений от внешних платформ (Telegram, WhatsApp, виджет на сайте);
- отправка ответов обратно через callback URL.

6.3 Панель мониторинга

Grafana-дашборд для наблюдения за работой системы (метрики, алерты, логи). Доступен операторам и администраторам.

7 Требования к надёжности, безопасности и условия эксплуатации

7.1 Требования к надёжности

– время доступности (uptime) — не менее 99,5% в месяц;
– автоматический перезапуск сервисов (liveness/readiness probes);
– репликация ключевых компонентов для исключения единых точек отказа;
– резервное копирование базы знаний и метаданных моделей не реже раза в сутки;
– graceful degradation — при недоступности NLP-сервиса вопросы автоматически направляются менеджерам.

7.2 Требования к безопасности

– аутентификация через JWT-токены;
– ролевая модель доступа (RBAC): администратор, менеджер, API-клиент;
– шифрование данных при передаче (TLS 1.3);
– изоляция данных клиентов (мультитенантность на уровне БД);
– аудит-логирование действий пользователей;
– сканирование Docker-образов на уязвимости (Trivy).

7.3 Условия эксплуатации

– среда выполнения: Kubernetes-кластер (v1.28+);
– минимальные ресурсы: 3 узла, по 4 vCPU / 16 ГБ RAM;
– поддержка облачных провайдеров: AWS EKS, GCP GKE, Yandex Cloud MKS, bare-metal;
– требуемые зависимости: Kubernetes, Helm 3, Docker.

8 Документация

В рамках ВКР разрабатывается следующая документация:

1) **Текст ВКР** — оформляется по ГОСТ 7.32-2017 и Положению о ГИА Университета ИТМО. Объём основной части — не менее 40 страниц.
2) **Техническая документация:**
   - README.md — описание проекта, инструкция по быстрому старту;
   - ARCHITECTURE.md — описание архитектуры и компонентов;
   - API-документация (автогенерация из OpenAPI-спецификации);
   - Deployment Guide — инструкция по развёртыванию;
   - Helm Chart README — описание параметров Helm-чарта.
3) **Презентация** для защиты ВКР (10–15 слайдов).
4) **Аннотация** — формируется в ИСУ.

9 Стадии и этапы разработки

№	Этап	Срок	Результат
1	Анализ предметной области. Обзор FAQ-систем и MLOps-решений	Сентябрь 2025	Аналитический обзор
2	Формирование требований. Составление ТЗ	Октябрь 2025	ТЗ (настоящий документ)
3	Проектирование архитектуры. Выбор NLP-модели и стека	Ноябрь 2025	Архитектурная схема
4	Разработка NLP-сервиса и API. Интеграция с векторной БД	Дек. 2025 – Янв. 2026	MVP backend
5	Реализация механизма дообучения и CI/CD-конвейера	Февраль 2026	Рабочий прототип
6	Настройка Kubernetes-инфраструктуры, мониторинга	Март 2026	Развёрнутая платформа
7	Тестирование (функциональное, нагрузочное)	Апрель 2026	Отчёт о тестировании
8	Оформление текста ВКР. Подготовка презентации	Май 2026	Текст ВКР
9	Предзащита и защита ВКР	Июнь 2026	Защита

10 Порядок контроля и приёмки

10.1 Текущий контроль

– еженедельные встречи с руководителем ВКР;
– промежуточные демонстрации работоспособности компонентов;
– code review разработанного кода;
– отчёты о прохождении этапов в соответствии с планом-графиком.

10.2 Критерии приёмки

1) Система принимает вопрос клиента через API и возвращает релевантный ответ из базы знаний.
2) При неизвестном вопросе происходит эскалация менеджеру; после получения ответа модель дообучается автоматически.
3) CI/CD-конвейер автоматически тестирует, собирает и развёртывает обновлённую модель в Kubernetes-кластере.
4) Мониторинг отображает метрики работы системы (latency, доля эскалаций, confidence).
5) Развёртывание новой версии модели происходит без простоя сервиса (zero-downtime deployment).
6) Текст ВКР оформлен в соответствии с требованиями ГОСТ и Университета ИТМО, оригинальность не менее 60%.

10.3 Итоговая приёмка

Итоговая приёмка осуществляется в форме защиты ВКР перед Государственной экзаменационной комиссией. Защита включает:

– доклад (7–10 минут) с презентацией;
– демонстрацию работоспособности системы (live demo или видеозапись);
– ответы на вопросы членов комиссии;
– учёт отзыва руководителя ВКР.